

VoiceFlow 项目说明书

一、问题背景

1.1 传统图形绘制工具的交互局限

在流程图、架构图、思维导图等结构化图形的日常绘制场景中，主流工具（如 Draw.io、Figma、ProcessOn）均依赖图形用户界面（GUI）的鼠标拖拽与键盘快捷键组合操作。这种交互模式在以下场景中暴露明显局限：**①讨论思维与节奏打断**：在会议场景下，参会者的思维被鼠标点击打断，创意难以得到**实时视觉化**呈现。**②移动与轻量场景困难**：在平板、手机或投屏环境下，精细的鼠标操作不可用或体验极差，用户难以完成准确的节点定位和连线操作。



图 1 传统图形绘制工具

1.2 语音交互技术发展现状与机遇

近年来，语音交互技术取得了长足进步，为新型人机交互范式奠定了基础：**①语音识别（ASR）方面**：Web Speech API 已在主流浏览器中提供原生中文普通话识别能力，识别准确率在安静环境下可达 95% 以上。**②大语言模型（LLM）方面**：以 GPT-5、Claude 为代表的 LLM 展现了强大的语义理解与结构化输出能力。**③行业趋势方面**：将语音作为生产力工具的输入模态，能够有效解放用户的双手和视觉注意力，让用户专注于内容创作本身而非工具操作。

1.3 VoiceFlow 项目定位与目标

①高频命令低延迟，复杂命令高智能：撤销、重做、缩放等高频确定命令通

过本地规则引擎直接执行，不调用 AI，实现快捷键级别的响应速度；新建完整图表、复杂修改等深度理解任务由 LLM 驱动，兼顾智能化。

②**结构化数据为王**：系统围绕 Diagram JSON 中间层设计——AI 只输出符合类型定义的标准化图结构，不直接操作画布；所有的修改、撤销、版本管理、导出均基于这一数据结构，确保可维护、可审计、可迁移。

③**容错而非回避错误**：系统通过三层 ASR 后纠错、多级路由降级、实体消歧、操作前置校验与后置校验等机制，在面对语音识别错误、用户表达歧义、AI 输出异常时主动修复或安全回退，而不是盲目执行或直接崩溃。

二、需求分析

2.1 目标用户与使用场景

表 1 用户画像表

用户画像	典型特征	核心痛点
产品经理	日常需要绘制流程图、业务架构图	花大量时间在工具操作上而非内容设计；会议中无法实时改图
技术管理者	需要快速绘制系统架构图、数据流图进行技术方案沟通	手动拖拽节点效率低；架构图频繁迭代，每次修改都需要重新排版
教师	教学过程中需要板书式地绘制流程图、思维导图讲知识	讲授过程中切换工具打断思路；无法实时根据学生反馈调整图形
会议主持人	头脑风暴、规划讨论	讨论节奏快，手绘跟不上思路

2.2 功能需求

VoiceFlow 的功能需求覆盖语音指令驱动绘图创作的全链路。支持中文普通话持续识别与实时字幕，配合三层本地纠错机制。指令解析层采用四层路由优先降级——Fast Path 直通 18 种高频命令（撤销/缩放/布局/导出等）零 AI 延迟、Simple Path 以正则模式确定性处理 20 余种节点/连线增删改操作、Workflow Path 批量执行主题/版本/场景切换、Agent Path 由 LLM 兜底复杂图表生成与上下文修改并支持主动补全和关键歧义反问。任务调度层将连续语音分割为可执行队列，允许即时命令同步执行。画布层支持 9 种节点、4 种连线样式、Dagre+ELK 双引擎布局、4 种主题与汇报模式。持久化层提供 30 步撤销/重做和命名版本管理。

能力层	核心功能	覆盖范围
语音输入	持续识别 / 实时字幕 / 三层 ASR 纠错 / 文字降级	中文普通话，本地 校准
指令解析	Fast (18 种) / Simple (20+模式) / Workflow (14 种) / Agent (LLM 兜底)	四层优先降级
任务调度	句法边界拆分 / 即时命令同步执行 / 分片自动合并 / 队列可见	连续语音→离散任 务
画布操作	9 种节点 / 4 种连线 / 增删改移插复 / 正交路由	零鼠标/键盘操作
布局美化	Dagre 多候选布局 / ELK 二遍美化 / 4 种主题 / 汇报模式	TB/LR 两种方向
版本管理	30 步撤销/重做 / 命名版本持久化 / 替换前自动备份	localStorage
导出能力	JSON / SVG / PNG	导出前自动 fitView
语音反馈	结果播报 / 错误提醒 / 反问播报 / 麦克风自激防护	闭环反馈

三、技术方案

3.1 系统总体架构

VoiceFlow 采用纯前端分层架构，语音识别、指令解析、画布渲染、布局计算全部在浏览器端完成。系统分为五层，自底向上依次为：

语音接入层：基于 Web Speech API 实现麦克风音频捕获与中文普通话持续语音识别，通过 VoiceProvider 接口抽象支持未来替换为 Whisper 或云端 ASR。

指令理解层：ASR 输出的文本经三层本地纠错（错词映射→槽位上下文→拼音评分），再按句法边界拆分为离散任务，最后由 CommandRouter 通过四层优先降级路由（Fast → Simple → Workflow → Agent）分发到对应执行路径。

业务逻辑层：指令转换为 11 种 DiagramOperation，由 OperationExecutor 在 Diagram 深拷贝上执行，前后分别经前置校验和后置校验。结构性操作后自动触发 Dagre/ELK 布局引擎。

状态管理层：基于 Zustand 的 9 个独立 Store 分别管理 Diagram 状态与撤销/重做、语音状态、命令路由、Agent、版本快照、画布视图等，职责互不耦合。

UI 渲染层：React 19 + React Flow 12 渲染只读画布，Diagram JSON 经

canvasTypes 转换后展示，禁用全部鼠标键盘交互。




图 2 系统整体架构图

3.2 指令理解的准确性与容错性

语音指令的准确理解是纯语音绘图工具的核心挑战。VoiceFlow 从 ASR 纠错、路由匹配、实体解析、降级兜底四个层面构建容错体系。

ASR 后纠错：ASR 输出的原始文本经过三层递进纠错。第一层为 19 条硬编码正则替换。第二层解析命令模式中的目标槽位，通过拼音相似性和编辑距离与画布现有节点标签匹配，仅存在唯一同音目标时才替换。第三层结合 106 个静态领域术语（含 51 个别名）与动态画布上下文（节点/边标签、最近命令）构建词典，对每个文本跨度计算加权相似度

四层路由优先降级：CommandRouter 按优先级从高到低依次尝试四种路径。Fast Path 精确或包含匹配关键词，置信度 0.92。Agent Path 通过图表生成模式（“画一个”“生成一张”等 33 个模式）和上下文修改模式（正则检测“把…改…”“连接…到…”等 7 类）触发，置信度 0.72~0.9。三种路径均未命中时自动降级为 agent，置信度 0.55。

用户语音 → Web Speech API → ASR 三层纠错 → 任务分割 → 四层路由

└─ Fast (18 种高频命令，不走 AI)

└─ Simple (20+正则模式，确定性执行，不走 AI)

└─ Workflow (主题/版本/场景)

└─ Agent (LLM 兜底，自动降级)

OperationExecutor (深拷贝+双校验) → 自动布局 (Dagre/ELK) → React Flow 只读画布

实体解析：语音引用画布对象时支持三层匹配——临时对象编号（“物体 1”“物体 2”，含中文数字）、标签精确/包含/字符重叠三级匹配、语义模糊匹配（“失败”匹配“否/异常/错误”等）。

Agent 兜底与修复：Agent 输出经过 JSON 解析 → Schema 校验 → 逻辑验真的三步规范化流程。输出不合法时自动向 LLM 发送修复请求重试。Agent 反问进入 clarifying 状态等待回答，下一句语音作为回答续接原任务。




图 3 语言指令容错理解

3.3 语音到绘图操作的响应延迟

VoiceFlow 通过任务分割调度、Fast Path 零 AI、即时命令同步执行、分片合并四类策略控制响应延迟。

任务队列调度：连续语音实时拆分为离散任务，进入任务队列。drainTasks 逐个顺序执行，每个任务经历 `queued` → `executing` → `verifying` → `completed` 状态流转，UI 实时展示进度。新任务在旧任务执行完毕前排队等待，避免并发冲突。

Fast Path 零 AI 延迟：Fast Path 包含 18 种高频命令（撤销、重做、缩放、布局切换、暂停、继续、取消、导出等），完全通过关键词匹配后直接调用对应 Store 方法或浏览器 API，全程无网络请求和 LLM 调用。撤销/重做、放大/缩

小等命令实测延迟达到快捷键级体验。架构约束明确要求“Fast Path 禁止调用 AI”，从根本上杜绝 AI 延迟影响高频操作。

即时命令同步执行：部分低风险即时命令标记为 `readiness: 'immediate'`，可在用户持续说话的同时立即执行，不需要等待录音结束。判断条件为 `route === 'fast'` 且命令在 `IMMEDIATE_FAST_COMMANDS` 集合中且置信度 ≥ 0.9 。

分片自动合并：浏览器 Web Speech API 可能将同一段话语的最终识别结果分多个 `final` 事件发送。`appendTasks` 的 `shouldMergeFinalFragment` 检测前一任务 `acceptsFinalContinuation && readiness === 'after_recording'` 且新任务也来自 `final` 时，将两段文本合并为同一任务，避免指令被拆碎后语义不完整导致路由出错。




图 4 响应延迟应对

3.4 复杂指令的拆解与执行能力

VoiceFlow 从任务边界分割、从句合并、操作执行系统、语义空间操作、Agent 主动补全五个方面实现对复杂指令的拆解与执行。

句法边界分割：按强边界模式拆分——句号/感叹号/问号/分号，以及“然后/接着/随后/最后”等时序连接词和“再看/再放/再缩”等“再+动词”组合。例如“画一个用户登录流程图，然后添加一个验证码节点”拆分为两个独立任务。

从句合并：逗号分隔的短语不直接拆分，而是经 `mergeDependentCommaClauses` 判断其是否为独立任务。如“放左边”“改成红色”“设为蓝色”等修饰短语被识别为从属从句（`isIndependentTask` 返回 `false`），合并到前一个主句。因此“画一个正方形，放左边”保持为一个复合任务。

操作执行系统：11 种 `DiagramOperation` 覆盖全程绘图能力。结构性操作执行后自动触发布局引擎重新计算坐标；非结构性操作（`move_node`、`update_node`、`align_nodes` 等）保持当前布局。`delete_node` 支持智能重连——若被删除节点仅有一入一出两条边，则自动创建一条绕过该节点的直连边。所有操作在 `Diagram` 深拷贝上执行，前置校验确保操作前提满足，后置校验确认 `diagram` 产生实质性变化。

语义空间操作：Agent 修改节点位置时优先输出语义操作，由本地计算像素坐标，而非依赖 LLM 直接输出坐标。支持 `left_of`/`right_of`/`above`/`below` 四种相对关系并自动计算间距；`alignNodes` 支持水平/垂直对齐；`setEdgeEndpoints` 修改连线方向。这种“AI 输出语义→本地求解坐标”的架构避免了 LLM 计算坐标不准确的问题。

Agent 主动补全与关键歧义反问：明确表达“画/生成/创建某类图”的请求，LLM 主动补全缺失的普通细节（如图表类型、节点数量），不需要用户反复补充。仅当存在会明显改变图表含义的关键歧义时（如用户只说了“画一个流程”但未指定主题），才返回 `clarification` 反问。反问进入 `clarifying` 状态后，下一句语音或文字作为回答续接原始任务，不丢失原指令。

四、创新点

4.1 确定性命令优先的混合路由架构

纯语音绘图全部走 AI 则延迟高达数秒，全部走规则则覆盖不全。VoiceFlow 提出四层递进路由架构（Fast → Simple → Workflow → Agent），按优先级从高到低依次匹配，高置信度路径短路低置信度路径。Fast Path 的 18 种高频命令（撤销/缩放/布局/导出等）完全通过关键词匹配直通对应 API，零 AI 调用；Simple Path 以 20 余种正则模式确定性执行节点/连线增删改操作；Workflow Path 处理主题美化、版本管理、场景加载等批量操作；Agent Path 作为兜底层。




图 5 四级递进路由

4.2 连续语音自动分割与即时命令同步执行

用户在绘图场景中的自然表达往往是连贯的长句——“画一个用户登录流程图，从打开 App 开始，判断是否已登录，已登录进首页，未登录去登录页……然后加一个验证码校验，再把失败分支改成红色虚线”。VoiceFlow 的能够自动将这种长串语音拆解为离散的可执行任务。它基于强边界确定必然拆分点，同时对逗号分隔的修饰短语进行依赖判断，将从属短语合并到主句而非盲目拆分。在此之上，部分低风险确定性命令（加三角形、看全图、放大、缩小、切换布局、暂停等）在路由命中后无需等待录音结束即可立即执行，其余复杂任务按拆分

后的顺序逐个执行。两者结合让用户无需等待整段话说完，大幅压缩了感知延迟。

五、测试效果与展示

5.1 专业图表模式

VoiceFlow 支持流程图、架构图、用例图、思维导图、框架图等结构化图形。用户只需说出图类型和主题，如“画一个用户登录流程图”，系统即可自动生成包含节点、连线、分支和判断逻辑的完整可编辑图形，并自动完成排版和美化。




图 6 演示图

5.2 自由画图模式

VoiceFlow 还支持自由画图模式，便于幼师授课、绘图探索



图 6 自由绘图模式